

**리뷰 텍스트 분석 기반
카공하기 좋은 카페 추천 지도
프로젝트 보고서**

2026 . 06. 22

제 출 문

본 보고서를 『빅데이터 분석 및 응용 팀 프로젝트』에 관한 최종 결과 보고서로 제출합니다.

2026 . 06. 23

용인대학교

지도교수 박 진 수

팀장 이 예 진

팀원 최 희 원

이 혜 원

이 윤 서

목 차

제1장. 프로젝트 선정 배경 및 목적	1
1. 프로젝트 선정 배경	1
2. 프로젝트의 목적 및 전체 분석 흐름	1
제2장. 데이터 수집 및 전처리	2
1. 데이터 수집 범위	2
2. 수집 데이터 항목	2
3. 카카오-네이버 장소 매칭	2
4. 분석 대상 필터링	3
5. 거리 및 프랜차이즈 정보	3
제3장. 리뷰 텍스트 분석 방법	4
1. 리뷰 문장 분리	4
2. 카공 특성 정의	4
3. 카공 특성 태깅 결과	4
4. 감성 분석 방법	5
5. 특성별 감성 분포	5
제4장. 카공 적합도 점수 산정 및 추천 결과	6
1. 특성별 점수 산정	6
2. 최종 점수 산정 방식	6
3. 후처리 기준	7
4. 후처리 후 최종 등급 분포	7
5. 최종 추천 후보 TOP 10	7
6. 추천 지도 시각화	8
7. 추천 후보와 비추천 그룹 비교	8

제5장. 추천 모델 비교 및 주요 요인 분석	9
1. 추천 모델의 역할과 성능 비교	9
2. 주요 요인 분석	9
제6장. 결론 및 한계점	10
1. 프로젝트 결과 요약	10
2. 기대 효과	10
3. 한계점 및 향후 개선 방향	10
4. 최종 결론	11

제1장. 과제 선정 배경 및 목적

1. 과제 선정 배경

최근 대학생들은 시험공부, 프로젝트 수행, 자격증 공부 등을 위해 카페를 학습 공간으로 활용하는 경우가 많음. 특히 학교 주변 카페는 강의 전후에 접근하기 쉽고, 도서관보다 자유로운 분위기에서 공부할 수 있다는 장점이 있어 많은 학생이 이용함. 그러나 실제로 카페를 선택할 때는 단순히 거리가 가까운지, 별점이 높은지, 리뷰 수가 많은지 만으로는 해당 카페가 학습 공간으로 적당한지에 대해서 충분한 판단을 하기 어려움.

별점, 거리, 리뷰 수, 인기 순위와 같은 일반적인 지표는 카페의 전반적인 만족도를 파악하는 데에는 도움이 되지만 공부하기 좋은 카페인지 판단하기에는 한계가 있음.

따라서 카공(카페에서 공부)에 적합한 카페를 추천하기 위해서는 리뷰 속에 포함된 학습 환경 관련 정보를 분석할 필요가 있음. 방문자 리뷰에는 조용함, 좌석, 콘센트, 혼잡도, 체류 적합성 등 학습 환경과 관련된 정보가 포함되어 있으며, 이를 분석하면 카페의 학습 공간 적합성을 구체적으로 평가할 수 있음.

본 프로젝트는 이러한 문제의식에서 출발함. 용인대학교 주변부터 기흥역 일대의 카페 데이터를 수집하고, 방문자 리뷰에서 카공과 관련된 특성을 추출하여 학습 공간으로써의 적합도를 산정하고자 했음. 이를 통해 단순히 별점이 높은 카페가 아니라, 실제 리뷰에서 공부하기 좋은 조건이 드러나는 카페를 추천하는 것을 목표로 하였음.

2. 프로젝트의 목적 및 전체 분석 흐름

본 프로젝트의 목적은 용인대학교 주변 카페 리뷰를 기반으로 카공하기 좋은 카페를 추천하는 데이터 분석 파이프라인을 구축하는 것임. 이를 위해 카카오맵 API를 활용하여 카페 기본 정보를 수집하고, 네이버 플레이스에서 별점, 리뷰 수, 영업시간, 방문자 리뷰를 수집함. 이후 수집된 데이터를 정제하고, 카카오맵과 네이버 플레이스 데이터를 매칭하여 분석 가능한 데이터셋을 구성함.

리뷰 분석 과정에서는 방문자 리뷰를 문장 단위로 분리하고, 카공 관련 특성이 포함된 문장을 추출함. 카공 특성은 조용함, 콘센트, 좌석, 혼잡도, 체류 적합성, 공부 적합성, 가격대, 영업시간, 와이파이가로 정의함. 각 문장에 포함된 특성을 태깅한 뒤, 감성 분석을 통해 해당 특성이 긍정적으로 언급되었는지, 부정적으로 언급되었는지 판단함.

최종적으로 카페별 특성 점수, 카공 감성 점수, 거리 점수, 별점 점수, 리뷰 신뢰도를 결합하여 카공 적합도 점수를 산정한다. 또한 카공 추천 목적과 맞지 않는 업종을 후처리 단계에서 제외하여 최종 추천 후보를 도출함. 이와 함께 Logistic Regression, Random Forest, XGBoost 모델을 활용하여 추천 라벨 분류 성능을 비교하고, 카공 추천에 영향을 미치는 주요 요인을 분석함.

이 흐름에서 가장 중요한 부분은 일반 리뷰 데이터에서 카공 관련 정보를 추출하는 과정임. 전체 리뷰에는 음료 맛, 직원 친절도, 매장 분위기, 가격 등 다양한 내용이 섞여 있기 때문에, 카공과 관련된 문장만 선별하고 이를 특성별로 분류하는 과정이 필요하다.

제2장. 데이터 수집 및 전처리

1. 데이터 수집 범위

데이터 분석 범위는 프로젝트의 목적에 맞게 용인대학교 주변부터 기흥역 일대까지로 설정함. 이 구간은 용인대학교 학생들이 실제로 이동하거나 카페를 이용할 가능성이 있는 범위이며, 학교 주변 상권과 대중교통 접근성을 함께 고려할 수 있는 구간임.

카페 기본 정보는 카카오맵 API를 통해 수집하였다. 카카오맵 API에서는 카페명, 주소, 위도, 경도, 전화번호, 카카오맵 URL 등 장소의 기본 정보를 확보함. 이후 각 카페에 대해 네이버 플레이스 정보를 검색하여 별점, 리뷰 수, 영업시간, 마감 시간, 방문자 리뷰 텍스트를 수집함.

초기 수집 결과 카카오 API 기준 카페 100개가 확보되었고, 네이버 플레이스에서는 원본 리뷰 745개가 수집되었음. 이후 매칭 및 필터링 과정을 거쳐 최종적으로 60개 카페와 580개 리뷰가 분석 대상으로 선정됨. 수집 결과의 세부 항목과 활용 파일은 부록 표 1에 제시하였음.

2. 수집 데이터 항목

카카오맵 API와 네이버 플레이스에서 수집한 항목은 서로 다르다. 카카오맵 API는 장소의 기본 위치 정보와 식별 정보를 확보하는 데 적합하고, 네이버 플레이스는 별점, 리뷰 수, 영업시간, 방문자 리뷰와 같은 평가 정보를 확보하는 데 유용하다. 따라서 두 데이터 출처를 결합하여 분석용 데이터셋을 구성함.

카카오맵 API에서는 카페명, 주소, 위도, 경도, 전화번호, 카카오 장소 URL을 수집했고, 네이버 플레이스에서는 네이버 장소명, 별점, 리뷰 수, 영업시간, 마감 시간, 네이버 지도 URL을 수집함. 네이버 방문자 리뷰에서는 리뷰 텍스트, 리뷰 순서, 카페 ID를 확보하여 리뷰 텍스트 분석에 활용함. 또한 자체 계산을 통해 직선거리, 거리 구간, 프랜차이즈 여부를 추가함. 수집 항목별 역할은 부록 표 2에 정리함.

카카오맵 API로 수집한 원본 카페 데이터는 'cafes_raw.csv'에 저장됐으며, 네이버 장소 정보는 'naver_place_info.csv', 네이버 방문자 리뷰는 'naver_reviews.csv'에 저장함. 이처럼 데이터 출처별로 결과물을 분리한 이유는 수집 과정의 오류를 추적하고, 이후 전처리 단계에서 어떤 데이터가 어떤 방식으로 결합이 되었는지 확인하기 위함임.

3. 카카오-네이버 장소 매칭

카카오맵과 네이버 플레이스는 같은 카페라도 장소명 표기가 다를 수 있음. 예를 들어 카카오맵에서는 지점명이 포함되어 있지만 네이버에서는 간략한 이름으로 표시되거나, 띄어쓰기와 특수문자 사용 방식이 다를 수 있음. 따라서 두 데이터가 같은 장소를 가리키는지 판단하기 위해 장소명 정규화와 문자열 유사도 계산을 수행함.

장소명에서 특수문자, 공백, 대소문자 차이를 제거한 뒤 카카오 장소명과 네이버 장소명의 유사도를 계산함. 그리고 유사도 기준에 따라 'matched', 'not_found', 'ambiguous', 'manual_check' 상태로 분류했음. 기본 분석에는 'matched' 상태의 카페를 사용함. 기본 분석에는 matched 상태의 카페를 사용했음.

매칭 결과 전체 100개 카페 중 81개가 자동 매칭됐으며, 자동 매칭 성공률은 약 81%임. 나머지 19개는 네이버 장소 검색에 실패했거나, 장소명이 애매하여 수동 확인이 필요한 대상으로 분류됐음. 세부 매칭 결과는 부록 표 3에 제시함.

4. 분석 대상 필터링

장소 매칭 이후에는 실제 분석에 사용할 카페와 리뷰를 필터링했음. 우선 카카오-네이버 매칭에 성공한 카페를 중심으로 분석 대상을 구성함. 또한 리뷰 수가 지나치게 적은 카페는 카공 적합도를 판단하기 어렵기 때문에 제외함. 이 외에도 키즈카페, 보드게임카페, 애견 카페처럼 카공 추천 목적과 맞지 않는 업종은 분석 또는 최종 후처리 단계에서 삭제했음.

필터링 결과 최초 수집 카페 100개 중 매칭 성공 카페는 81개였고, 최종 분석 대상 카페는 60개로 정리되었음. 제외 카페는 총 40개임. 카페 필터링 과정의 세부 내용은 부록 표 4에 정리함.

리뷰 데이터 역시 필터링을 거쳤음. 원본 리뷰 745개 중 중복 리뷰, 결측 리뷰, 분석 대상에서 제외된 카페의 리뷰를 제거한 결과 최종 분석에는 580개의 리뷰가 사용되었음. 필터링 후 분석에 사용된 리뷰는 전체 원본 리뷰의 약 77.9%임. 최종 분석 대상 카페는 60개이며, 카페당 평균적으로 약 9.67개의 리뷰가 분석에 사용되었음. 리뷰 필터링 결과는 부록 표 5에 제시하였음.

5. 거리 및 프랜차이즈 정보

카공 장소를 선택할 때 접근성은 중요한 요소 중 하나이다. 따라서 최종 분석 대상 카페 60개에 대해 용인대학교 기준 직선거리를 계산했다. 직선거리는 위도와 경도 정보를 활용해서 계산했으며 거리 구간은 300m 이내, 700m 이내, 1.3km 이내, 1.3km 초과로 구분함.

거리 구간별로는 직선거리 300m 이내 카페가 21개, 700m 이내 카페가 12개, 1.3km 이내 카페가 4개, 1.3km 초과 카페가 23개로 나타났다. 거리 구간별 분포는 부록 표 6에서 확인할 수 있음.

중앙값은 419m로 비교적 가까운 카페가 많지만, 평균 직선거리는 약 1,412m로 나타났다. 이는 일부 먼 카페들이 평균을 끌어올렸기 때문임. 최소 직선거리는 86m, 최대 직선거리는 5,412m로 나타났다. (거리 통계는 부록 표 7 참고) 이러한 거리 정보는 최종 점수 산정에서 보조 요소로 반영함. 추가적으로 프랜차이즈 여부를 분류하는 작업도 거쳤음. 최종 분석 대상 중 개인카페는 46개, 프랜차이즈 카페는 14개로 나타남. 프랜차이즈 중에서는 메가커피 5개, 컴포즈커피 3개가 가장 많이 포함됨.

제3장. 리뷰 텍스트 분석 방법

1. 리뷰 문장 분리

방문자 리뷰는 하나의 리뷰 안에 여러 정보가 함께 포함되는 경우가 많음. 예를 들어 한 리뷰에 “커피가 맛있고, 조용해서 공부하기 좋고, 좌석도 넓다” 라는 문장이 포함되어 있다면, 이 리뷰에는 맛, 조용함, 공부 적합성, 좌석 정보가 동시에 들어 있다. 따라서 리뷰 단위로 분석하면 특정 특성이 정확히 어떤 감성으로 언급되었는지 판단하기 어려움.

이를 해결하기 위해 우선 리뷰를 문장 단위로 분리했음. 이어서 문장 단위 분리를 통해 각 문장에서 어떤 카공 특성이 언급되었는지 확인하고 해당 문장의 감성을 특성별로 분석할 수 있도록 함.

최종 분석 리뷰 580개는 총 1,738개 문장으로 분리되었음. 이 중 카공 관련 문장은 124개로, 전체 문장의 약 7.1%에 해당함. 한 문장에 여러 특성이 포함될 수 있도록 확장한 결과 문장-특성 쌍은 137개로 구성됐음. 이는 일반 카페 리뷰에서 카공 관련 정보가 일부에만 포함되어 있음을 보여줌. 따라서 전체 리뷰를 단순히 분석하기보다 카공 관련 문장만 선별하여 분석하는 과정이 필요했음. 리뷰 문장 분리 결과는 부록 표 8에 정리하였음.

2. 카공 특성 정의

학습 적합도를 판단하기 위해 본 프로젝트에서는 9개의 카공 관련 특성을 정의했음. 주요 특성은 조용함, 콘센트, 좌석, 혼잡도, 체류 적합성, 공부 적합성이다. 여기에 가격대, 영업시간, 와이파이를 보조 특성으로 포함했음. 각 특성의 정의와 예시 키워드는 부록 표 9에서 확인할 수 있음.

카공에 가장 직접적으로 관련된 요소는 조용함, 좌석, 콘센트, 혼잡도, 체류 적합성, 공부 적합성임. 조용함은 집중도와 관련되고, 좌석은 장시간 이용 편의성과 관련되며, 콘센트는 노트북 사용 가능성과 연결됨. 혼잡도는 실제 이용 시 집중을 방해할 수 있는 요소이고 체류 적합성은 오래 머무를 수 있는 분위기와 관련됨.

가격대, 영업시간, 와이파이는 카공 환경을 보조적으로 설명하는 특성이다. 다만 최종 점수 산정에서는 핵심 카공 특성의 비중을 더 높게 두었음.

3. 카공 특성 태깅 결과

리뷰 문장 중 카공 관련 키워드가 포함된 문장을 선별하고 해당 문장이 어떤 특성과 관련되는지 태깅했음. 한 문장에 여러 특성이 포함될 수 있으므로 하나의 문장이 여러 문장-특성 쌍으로 확장될 수 있음.

예를 들어 “조용하고 좌석이 넓어서 오래 있기 좋다” 라는 문장은 조용함, 좌석, 체류 적합성 특성으로 동시에 태깅될 수 있음. 이러한 방식으로 최종적으로 137개의 문장-특성 쌍이 생성됨.

특성별 분포를 보면 가격대가 52개로 가장 많이 언급됐고 좌석 27개, 조용함 25개, 체류 적합성 13개, 공부 적합성 9개, 영업시간 7개 순으로 나타났다. 혼잡도와 콘센트는 각각 2개였으며 와이파이는 0개로 나타났다. 세부 분포는 부록 표 10에 제시하였음.

가격대 언급이 가장 많았지만 가격대는 카공 환경 자체를 직접 설명하는 요소라기보다는 보조적인 요소임. 실제 카공 적합도 산정에서는 조용함, 좌석, 체류 적합성, 공부 적합성 등 학습 환경과 직접 관련된 요소를 중심으로 반영했음.

콘센트와 와이파이는 카공에서 중요한 요소이지만 실제 리뷰에서는 거의 언급되지 않았음. 콘센트는 2개, 와이파이는 0개로 나타났으며 이는 리뷰 텍스트만으로 모든 카공 요소를 충분히 판단하기 어렵다는 한계를 보여줌.

4. 감성 분석 방법

카공 특성이 포함된 문장에 대해 긍정, 중립, 부정 감성을 분류하였다. 감성 분석은 문장과 특성을 함께 고려해서 수행했음. 예를 들어 “조용해서 좋다”는 조용함 특성에 대해 긍정으로 볼 수 있고, “사람이 많아서 공부하기 어렵다”는 혼잡도 또는 공부 적합성에 대해 부정으로 볼 수 있음.

감성 분석 과정에서는 먼저 라벨링 템플릿을 생성하고, 문장-특성 쌍에 대해 감성 라벨을 부여했음. 이후 텍스트를 TF-IDF 방식으로 벡터화하고 Logistic Regression 기반 감성 분류를 적용했다. 이러한 작업들이 수행된 결과는 ‘sentiment_result.csv’에 저장됨.

감성 분석 결과 전체 137개 문장-특성 쌍 중 긍정은 103개, 중립은 22개, 부정은 12개로 나타났다. 긍정 비율은 약 75.2%로 가장 높았음. 이는 수집된 카공 관련 리뷰 문장들이 대체로 긍정적인 표현을 포함하고 있음을 의미함. 감성 분석 결과는 부록 표 11에 정리하였음.

5. 특성별 감성 분포

특성별 감성 분포를 살펴보면 어떤 요소가 긍정적으로 언급됐고 어떤 요소가 부정적으로 언급됐는지 확인할 수 있음. 세부 감성 분포는 부록 표 12 제시하였음.

가격대는 52개 언급 중 긍정 44개로 긍정 비중이 높았다. 좌석은 긍정 20개, 중립 3개, 부정 4개로 나타났으며 조용함은 긍정 22개, 부정 3개로 나타났다. 체류 적합성은 긍정 5개, 중립 7개, 부정 1개로 중립 비중이 비교적 높았고 공부 적합성은 긍정 5개, 중립 4개로 분류되었음. 혼잡도는 2개 모두 부정으로 나타났는데, 이는 사람이 많거나 붐비는 환경이 카공에 부정적인 요소로 작용한다는 점을 보여줌.

이 결과를 통해 카공 추천에서 중요한 특성은 단순히 많이 언급된 요소가 아니라, 실제로 긍정 또는 부정 감성이 어떻게 나타났는지를 함께 고려해야 함을 확인할 수 있음.

제4장. 카공 적합도 점수 산정 및 추천 결과

1. 특성별 점수 산정

감성 분석 결과를 바탕으로 학습하기 좋은 카페를 추천하기 위해 카페별 · 특성별 점수를 계산함. 특성 점수는 해당 특성에 대해 긍정 문장과 부정 문장의 비율을 기준으로 산정함. 긍정과 부정이 모두 없는 경우에는 중립값인 50점으로 처리했음.

특성 점수 산정 공식은 다음과 같음.

$$\text{특성 점수} = \text{긍정 문장 수} / (\text{긍정 문장 수} + \text{부정 문장 수}) \times 100$$

특성별 평균 점수를 보면 가격대, 공부 적합성, 조용함, 좌석 등이 높은 점수를 보였음. 가격대는 31개 카페에서 52회 언급되었고 평균 점수는 91.94점으로 나타났음. 좌석은 19개 카페에서 27회 언급됐으며 평균 점수는 81.58점이었음. 조용함은 16개 카페에서 25회 언급됐고 평균 점수는 84.38점으로 나타났음. 체류 적합성은 11개 카페에서 13회 언급됐으며 평균 점수는 68.18점이었음. 공부 적합성은 5개 카페에서 9회 언급됐고 평균 점수는 90.00점으로 나타났다. 영업시간은 5개 카페에서 7회 언급됐으며 평균 점수는 80.00점이었음. 콘센트는 평균 점수 100.00점으로 나타났지만 언급 수가 2개뿐이므로 해석에 주의해야 함. 혼잡도는 2개 모두 부정으로 분류되어 평균 점수가 0점으로 나타남. 특성별 평균 점수는 부록 표 13에 정리하였음.

2. 최종 점수 산정 방식

카페별 최종 카공 적합도 점수는 카공 감성 점수, 거리 점수, 별점 점수를 결합해서 계산함. 카공 감성 점수는 리뷰 속 카공 관련 문장의 감성 분석 결과를 기반으로 하며 가장 높은 비중을 부여했음. 거리 점수는 용인대학교 기준 직선거리를 바탕으로 산정했고 별점 점수는 네이버 별점을 100점 기준으로 환산했음.

최종 원점수는 다음과 같이 계산함.

$$\text{최종 원점수} = \text{카공 감성 점수} \times 0.75 + \text{거리 점수} \times 0.15 + \text{별점 점수} \times 0.10$$

리뷰 수가 적은 카페가 우연히 높은 점수를 받는 문제를 줄이기 위해 리뷰 신뢰도도 적용했음.

$$\text{리뷰 신뢰도} = 0.7 + 0.3 \times \min(1, \text{리뷰 수} / 50)$$

최종적으로 보정 최종 점수는 다음과 같이 계산하였음.

$$\text{보정 최종 점수} = \text{최종 원점수} \times \text{리뷰 신뢰도}$$

이 구조에서 카공 감성 점수의 비중은 75%로 가장 큼. 이는 일반 별점이나 거리보다 실제 리뷰 속 카공 관련 정보가 추천 결과에 더 크게 반영되도록 하기 위한 것임. 거리 점수는 15%, 별점 점수는 10%로 보조적으로 반영하였음.

최종 발표용 등급은 ‘presentation_score’를 기준으로 산정했다. 점수가 90점 이상이면 ‘카공 성지’, 70점 이상 90점 미만이면 ‘추천’, 50점 이상 70점 미만이면 ‘보통’, 50점 미만이면 ‘비추천’으로 분류했음. 다만 카공 추천 목적과 맞지 않는 업종은 점수와 관계없이 후처리 단계에서 ‘제외’로 분류했음.

3. 후처리 기준

후처리 전 점수 계산 결과에서는 보드게임카페처럼 카공 추천 목적과 맞지 않는 장소가 높은 점수를 받을 수 있었음. 이는 해당 장소의 리뷰에 긍정적인 표현이 포함되어 있거나 별점, 리뷰 수가 높으면 점수 계산상 상위권에 포함될 수 있기 때문임. 그러나 보드게임 카페나 키즈카페, 애견카페 등은 일반적인 카공 추천 대상과 맞지 않으므로 최종 추천 후보에서는 제외할 필요가 있음.

따라서 후처리 단계에서는 카공 추천 대상이 아닌 업종을 제외하였음. 다만 거리 요소는 최종 점수 산정 단계에서 이미 거리 점수로 반영되었기 때문에 발표용 점수에서는 별도의 거리 감점을 추가로 적용하지 않음. 즉, 최신 후처리 기준에서는 업종 제외만 적용하고 발표용 점수는 보정 최종 점수인 ‘adjusted_final_score’를 그대로 사용하였음.

후처리 과정에서 보드게임카페인 보드빌과 레드버튼 용인역북점은 후처리 전에는 카공 성지 등급이었으나, 카공 추천 목적과 맞지 않는 업종으로 판단되어 최종 등급에서 제외로 분류됐다. 세부 내용은 부록 표 14에 제시하였음.

4. 후처리 후 최종 등급 분포

후처리 결과 최종 발표용 등급은 카공 성지, 추천, 보통, 비추천, 제외로 구분하였음. 최종적으로 카공 성지 9개, 추천 11개, 보통 26개, 비추천 12개, 제외 2개로 분류됐음. 후처리 후 최종 등급 분포는 부록 표 15에 정리하였음.

카공 성지와 추천 등급을 합친 최종 추천 후보는 총 20개임. 보통 이하 또는 제외로 분류된 카페는 40개임. 이 결과는 전체 분석 대상 60개 중 약 33.3%가 추천 후보로 분류되었음을 의미함. 추천 후보는 리뷰 기반 카공 감성 점수가 높고 최종 점수 기준을 충족한 카페들임.

5. 최종 추천 후보 TOP 10

최종 추천 후보는 총 20개이며 본문에서는 상위 10개 카페를 중심으로 제시함. 최종 추천 후보 TOP 10의 세부 순위와 점수는 부록 표 16에서 확인할 수 있음.

최종 1위는 커스텀커피 역북점으로 나타났다. 해당 카페는 카공 감성 점수 100점, 거리 점수 100점, 별점 점수 95.8점, 리뷰 신뢰도 1.0을 기록하여 최종 발표용 점수 99.58점을 받았음.

상위 10개 카페는 커스텀커피 역북점, 드롭탑 용인역북점, 지니어스, 밀크팜747, 커피인류 용인역북점, 메가MGC커피 명지대역점, 브라운리퀴드, 처인재, 트리아농, 카페다 용인시청점

순으로 나타났음. 이 중 1위부터 9위까지는 카공 성지로 분류됐고, 10위 카페다 용인시청점은 추천 등급으로 분류됐음.

상위권 카페들은 대부분 카공 감성 점수가 높게 나타났다. 특히 1위부터 6위까지는 카공 감성 점수가 모두 100점이었음. 이는 해당 카페들이 리뷰에서 조용함, 좌석, 공부 적합성 등 카공 관련 요소에 대해 긍정적으로 언급되었음을 의미함.

6. 추천 지도 시각화

최종 추천 결과는 표 형태뿐만 아니라 지도 형태로도 시각화하였음. 지도 시각화에는 위도와 경도 정보를 활용하였으며, 최종 추천 후보인 '카공 성지'와 '추천' 등급 카페를 지도 위에 표시하였다. 이를 통해 사용자가 추천 카페의 위치, 등급, 카공 점수, 주요 정보를 함께 확인할 수 있도록 하였음.

지도에서는 카페별 마커를 통해 추천 후보의 공간적 분포를 확인할 수 있으며, 사용자는 단순히 순위만 보는 것이 아니라 용인대학교와의 거리와 주변 위치를 함께 고려하여 카공 장소를 선택할 수 있음.

7. 추천 후보와 비추천 그룹 비교

최종 추천 후보와 비추천·보통·제외 그룹을 비교하여 어떤 요소가 추천 결과를 구분하는지 확인하였음. 세부 비교 결과는 부록 표 17에 제시했음.

추천 후보와 나머지 카페의 가장 큰 차이는 별점이 아니라 카공 감성 점수임. 추천 후보의 평균 별점 점수는 68.65점으로 비추천·보통·제외 그룹의 71.95점보다 낮았음. 그러나 추천 후보의 카공 감성 점수는 96.58점으로 비추천·보통·제외 그룹의 50.04점보다 훨씬 높았음.

이는 일반 별점만으로는 카공 적합도를 판단하기 어렵다는 점을 보여줌. 별점은 카페의 전반적인 만족도를 반영하지만 공부하기 좋은 환경인지를 직접적으로 설명하지는 않음. 반면 카공 감성 점수는 조용함, 좌석, 체류 적합성 등 실제 학습 환경과 관련된 리뷰 표현을 반영하므로 카공 추천에 더 적합한 지표로 볼 수 있음.

또한 추천 후보의 평균 직선거리는 1,745.85m로 비추천·보통·제외 그룹의 1,245.58m보다 더 길게 나타났음. 이는 최선 후처리 기준에서 별도의 거리 감점을 적용하지 않았기 때문임. 거리 요소는 최종 점수 산정 단계에서 이미 거리 점수로 반영되며, 후처리 단계에서는 업종 제외만 적용하였음. 따라서 거리가 멀더라도 리뷰 기반 카공 감성 점수가 높으면 추천 후보로 선정될 수 있었음.

제5장. 추천 모델 비교 및 주요 요인 분석

1. 추천 모델의 역할과 성능 비교

본 프로젝트에서 추천 모델은 실제 사용자 만족도를 직접 예측하는 모델이 아니라, 앞서 산정한 카공 적합도 점수와 추천 등급을 기준으로 생성된 라벨을 분류하는 모델임. 따라서 모델 성능은 실제 사용자가 만족할 가능성보다는 현재 점수 산정 기준을 얼마나 잘 재현하는지를 보여주는 지표로 해석해야 함.

추천 여부 분류를 위해 Logistic Regression, Random Forest, XGBoost 세 가지 모델을 비교했음. 각 모델은 동일한 데이터셋을 기반으로 학습됐으며, 평가 지표로 Accuracy, Precision, Recall, F1-score를 사용했음. 모델 성능 비교 결과 Logistic Regression이 Accuracy 0.9333, F1-score 0.9159로 가장 높은 성능을 보였음. Random Forest는 Accuracy 0.8833, F1-score 0.8278을 기록했고, XGBoost는 Accuracy 0.8333, F1-score 0.7566으로 가장 낮은 성능을 보였음. 모델별 세부 성능은 부록 표 18에 정리하였음.

현재 데이터셋은 최종 분석 대상 카페 60개로 규모가 크지 않기 때문에 복잡한 비선형 모델보다 단순한 선형 모델인 Logistic Regression이 더 안정적으로 작동한 것으로 해석할 수 있음. 또한 추천 라벨이 실제 사용자 평가가 아니라 점수화 기준에 의해 생성되었기 때문에 모델 비교 결과는 추천 시스템의 실사용 성능보다는 점수 산정 기준의 재현 가능성을 확인하는 보조 결과로 보는 것이 적절함.

2. 주요 요인 분석

모델별 중요도 분석 결과 세 모델 모두에서 조용함, 좌석, 체류 적합성이 주요 요인으로 나타났음. Logistic Regression에서는 좌석, 조용함, 체류 적합성이 상위 중요 특성으로 나타났고, Random Forest에서는 조용함과 좌석이 높은 중요도를 보였음. XGBoost에서는 체류 적합성, 조용함, 좌석이 주요 특성으로 나타났음. 모델별 중요도 순위는 부록 표 19부터 부록 표 22에 제시하였음.

세 모델에서 공통적으로 등장한 핵심 요인은 조용함_score, 좌석_score, 체류 적합성_score이다. 조용함은 소음이 적고 집중하기 좋은 환경을 의미하며, 좌석은 좌석 수, 테이블, 의자, 공간 여유와 관련됨.

체류 적합성은 오래 머물기 좋은 분위기와 이용 조건을 의미함. 공통 핵심 요인은 부록 표 23에 정리하였음.

이 결과는 본 프로젝트의 핵심 가설과도 일치함. 카공 추천에서는 단순한 별점보다 실제 학습 환경을 설명하는 요소가 중요하며 특히 조용함, 좌석, 체류 적합성이 카공 적합도를 판단하는 핵심 기준으로 작용함.

제6장. 결론 및 한계점

1. 프로젝트 결과 요약

본 프로젝트는 용인대학교 주변부터 기흥역 일대의 카페를 대상으로 리뷰 텍스트 분석 기반 카공 추천 시스템을 구축하는 것을 목표로 했음. 카카오맵 API를 통해 카페 100개를 수집하고, 네이버 플레이스에서 장소 정보와 방문자 리뷰를 수집함. 이후 카카오-네이버 장소 매칭과 필터링을 거쳐 최종 분석 대상 카페 60개와 리뷰 580개를 선정했음.

이후 리뷰 문장 분리, 카공 특성 태깅, 감성 분석, 점수 산정 과정을 거쳐 카공 성지 9개와 추천 11개를 도출하였으며, 최종 추천 후보는 총 20개로 정리되었음. 모델 비교에서는 Logistic Regression이 가장 높은 성능을 보였고, 조용함, 좌석, 체류 적합성이 공통적으로 주요 요인으로 나타났음.

2. 기대 효과

본 프로젝트는 일반 별점 중심의 카페 추천 방식에서 벗어나, 리뷰 속 학습 환경 관련 정보를 분석했다는 점에서 의미가 있음. 기존의 카페 추천 방식은 평점이나 거리 정보를 중심으로 제공되지만 카공 목적의 사용자에게는 조용함, 좌석, 콘센트, 혼잡도, 체류 가능성 등의 정보가 더 중요할 수 있음.

분석 결과를 통해 사용자는 단순히 별점이 높은 카페가 아니라 실제 리뷰에서 공부하기 좋은 조건이 드러나는 카페를 확인할 수 있음. 특히 용인대학교 학생들은 학교 주변 카페 중 공부하기 좋은 장소를 보다 쉽게 탐색할 수 있음. 또한 본 프로젝트의 분석 방식은 카공 지도뿐 아니라 혼잡하기 좋은 식당, 팀 프로젝트하기 좋은 공간, 조용한 작업 공간 추천 등 다른 장소 추천 서비스로도 확장 가능함.

3. 한계점 및 향후 개선 방향


본 프로젝트는 리뷰 텍스트 기반 분석이라는 점에서 몇 가지 한계가 있음. 전체 문장 1,738개 중 카공 관련 문장은 124개로 약 7.1%에 불과했고, 콘센트와 와이파이처럼 카공에 중요한 요소는 실제 리뷰에서 거의 언급되지 않았음. 또한 일부 카페는 카공 관련 문장 수가 적어도 긍정 문장 하나만으로 높은 점수를 받을 수 있어, 향후에는 언급 수 기반 신뢰도 보정이나 “근거 부족” 등급을 추가할 필요가 있음. 추천 모델 역시 실제 사용자 만족도 데이터가 아니라 점수화 기준으로 생성된 라벨을 학습했기 때문에, 모델 성능은 실제 만족도 예측이 아니라 현재 점수 산정 기준을 얼마나 잘 재현하는지를 의미함. 접근성 점수도 직선 거리 기반이므로 실제 도보 경로나 대중교통 편의성을 충분히 반영하지 못함.

향후에는 블로그 리뷰, 카카오맵 리뷰, 설문 데이터, 사용자 제보 등을 추가로 수집하여 카공 관련 데이터를 보완하고 콘센트, 와이파이, 좌석 수, 테이블 크기 등 리뷰에 잘 드러나지 않는 정보는 별도 정형 데이터로 수집할 필요가 있음. 또한 실제 도보시간 API를 연동해 접근성 점수를 개선하고, 실제 사용자 만족도 평가를 수집한다면 점수 기반 추천을 넘어 사용자 만족도 예측 모델로 확장할 수 있음.

4. 최종 결론

본 프로젝트는 용인대학교 주변 카페 리뷰를 분석하여 카공하기 좋은 카페를 추천하는 데이터 분석 과정을 구축함. 수집한 카페 100개와 리뷰 745개 중 최종 분석 대상 카페 60개, 리뷰 580개를 선정하고 리뷰 문장에서 카공 관련 특성과 감성을 추출하여 최종 추천 후보 20개를 도출했음. 분석 결과 카공 추천에서는 일반 별점보다 조용함, 좌석, 체류 적합성처럼 실제 학습 환경과 관련된 요소가 더 중요한 기준으로 나타났음. 이를 통해 리뷰 텍스트 분석을 활용하면 일반적인 평점 중심 추천보다 카공 목적에 더 적합한 장소 추천이 가능하다는 점을 확인했음.

5. 프로젝트 최종 결과물 [사진 첨부]



<부 록>

[표 1] 데이터 수집 결과 요약	14
[표 2] 수집 데이터 항목	14
[표 3] 카카오-네이버 장소 매칭 결과	14
[표 4] 분석 대상 필터링 결과	14
[표 5] 리뷰 필터링 결과	14
[표 6] 거리 구간별 카페 분포	15
[표 7] 거리 통계	15
[표 8] 리뷰 문장 분리 결과	15
[표 9] 카공 특성 정의	15
[표 10] 카공 특성별 문장 - 특성 쌍 분포	16
[표 11] 감성 분석 결과	16
[표 12] 특성별 감성 분포	16
[표 13] 특성별 평균 점수	16
[표 14] 후처리에서 제외된 카페	17
[표 15] 후처리 후 최종 등급 분포	17
[표 16] 최종 추천 후보 TOP 10	17
[표 17] 추천 후보와 비추천 · 보통 · 제외 그룹 비교	17
[표 18] 추천 모델 성능 비교	18
[표 19] Logistic Regression 중요도 TOP 5	18
[표 20] Random Forest 중요도 TOP 5	18
[표 21] XGBoost 중요도 TOP 5	18
[표 22] 모델별 중요도 TOP 5 비교	18
[표 23] 공통 핵심 추천 요인	18

[표 1] 데이터 수집 결과 요약

구분	결과	활용 파일
카카오 API 수집 카페	100개	cafes_raw.csv
네이버 장소 정보	100개	naver_place_info.csv
네이버 원본 리뷰	745개	naver_reviews.csv
최종 분석 대상 카페	60개	cafes_clean_filtered.csv
최종 분석 대상 리뷰	580개	naver_reviews_filtered.csv

[표 2] 수집 데이터 항목

데이터 출처	주요 수집 항목	활용 목적
카카오 API	카페명, 주소, 위도, 경도, 전화번호, 카카오 장소 URL	기본 장소 정보 수집
네이버 플레이스	네이버 장소명, 별점, 리뷰 수, 영업시간, 매장 사진, 네이버 지도 URL	평가 정보 및 장소 정보 보완
네이버 방문자 리뷰	리뷰 텍스트, 리뷰 수, 카페 ID	리뷰 텍스트 분석
자체 계산	직선거리, 거리 구간, 프랜차이즈 여부	접근성 및 보조 특성 분석

[표 3] 카카오 & 네이버 장소 매칭 결과

매칭 상태	개수	의미	활용 파일
matched	81개	동일 장소로 판단	cafes_clean.csv
not_found	11개	네이버 장소 검색 실패	cafes_clean.csv
ambiguous	4개	유사도 애매함	cafes_clean.csv
manual_check	4개	수동 확인 필요	cafes_clean.csv

[표 4] 분석 대상 필터링 결과

구분	개수	활용 파일
최초 수집 카페	100개	cafes_raw.csv
매칭 성공 카페	81개	cafes_clean.csv
최종 분석 대상 카페	60개	cafes_clean_filtered.csv
제외 카페	40개	cafes_raw.csv, cafes_clean_filtered.csv

[표 5] 리뷰 필터링 결과

구분	리뷰 수	활용 파일
원본 리뷰	745개	naver_reviews.csv
필터링 후 리뷰	580개	naver_reviews_filtered.csv

[표 6] 거리 구간별 카페 분포

거리 구간	카페 수
직선거리 300m 이내	21개
직선거리 700m 이내	12개
직선거리 1.3km 이내	4개
직선거리 1.3km 초과	23개

[표 7] 거리 통계

지표	값
평균 직선거리	약 1,412m
최소 직선거리	86m
최대 직선거리	5,412m
중앙값	419m

[표 8] 리뷰 문장 분리 결과

구분	개수	활용 파일
분석 대상 리뷰	580개	naver_reviews_filtered.csv
전체 문장	1,738개	review_sentences_all.csv
카공 관련 문장	124개	review_sentences_all.csv
문장-특성 쌍	137개	study_sentence_features.csv
카공 관련 문장 비율	약 7.1%	review_sentences_all.csv

[표 9] 카공 특성 정의

특성	설명	예시 키워드
조용함	소음, 분위기, 조용한 정도	조용, 한적, 시끄, 소음
콘센트	충전 가능 여부	콘센트, 충전, 전원
좌석	자리, 테이블, 의자, 공간	자리, 좌석, 테이블
혼잡도	사람 많음, 붐빔	붐비, 사람 많, 웨이팅
체류 적합성	오래 머물기 적합한지	오래, 눈치, 장시간
공부 적합성	공부·작업 직접 언급	공부, 카공, 노트북
가격대	가격 부담	가격, 저렴, 가성비
영업시간	늦은 시간 이용 가능성	늦게까지, 마감, 24시
와이파이	인터넷 이용 가능성	와이파이, wifi

[표 10] 카공 특성별 문장 - 특성 쌍 분포

특성	문장-특성 쌍 수	활용 파일
가격대	52	study_sentence_features.csv
좌석	27	study_sentence_features.csv
조용함	25	study_sentence_features.csv
체류 적합성	13	study_sentence_features.csv

[표 11] 감정 분석 결과

감성	개수	비율	활용 파일
긍정	103	약 75.2%	sentiment_result.csv
중립	22	약 16.1%	sentiment_result.csv
부정	12	약 8.8%	sentiment_result.csv

[표 12] 특성별 감성 분포

특성	긍정	중립	부정	총합
가격대	44	6	2	52
좌석	20	3	4	27
조용함	22	0	3	25
체류 적합성	5	7	1	13
공부 적합성	5	4	0	9
영업시간	5	2	0	7
콘센트	2	0	0	2
혼잡도	0	0	2	2

[표 13] 특성별 평균 점수

특성	등장 카페 수	언급 수	평균 점수	활용 파일
가격대	31개	52	91.94	cafe_feature_scores.csv
좌석	19개	27	81.58	cafe_feature_scores.csv
조용함	16개	25	84.38	cafe_feature_scores.csv
체류 적합성	11개	13	68.18	cafe_feature_scores.csv
공부 적합성	5개	9	90.00	cafe_feature_scores.csv
영업시간	5개	7	80.00	cafe_feature_scores.csv
콘센트	2개	2	100.00	cafe_feature_scores.csv
혼잡도	2개	2	0.00	cafe_feature_scores.csv

[표 14] 후처리에서 제외된 카페

카페명	후처리 전 등급	후처리 후 등급	제외 이유
보드빌	카공 성지	제외	보드게임카페
레드버튼 용인역북점	카공 성지	제외	보드게임카페

[표 15] 후처리 후 최종 등급 분포

발표용 등급	카페 수	활용 파일
카공 성지	9개	study_cafe_final_postprocessed.csv
추천	11개	study_cafe_final_postprocessed.csv
보통	26개	study_cafe_final_postprocessed.csv
비추천	12개	study_cafe_final_postprocessed.csv
제외	2개	study_cafe_final_postprocessed.csv

[표 16] 최종 추천 후보 TOP 10

순위	카페명	발표용 점수	등급	카공 감성 점수	직선거리
1	커스텀커피 역북점	99.58	카공 성지	100.00	86m
2	드롭탑 용인역북점	98.30	카공 성지	100.00	214m
3	지니어스	96.00	카공 성지	100.00	242m
4	밀크팜747	96.00	카공 성지	100.00	103m
5	커피인큐브 용인역북점	96.00	카공 성지	100.00	218m
6	메가MGC커피 명지대역점	93.75	카공 성지	100.00	424m
7	브라운리퀴드	91.19	카공 성지	88.89	107m
8	치인재	90.75	카공 성지	100.00	1,155m
9	트리아농	90.19	카공 성지	100.00	2,215m
10	카페더 용인시청점	89.05	추천	100.00	2,687m

[표 17] 추천 후보와 비추천 · 보통 · 제외 그룹 비교

항목	추천 후보 평균	비추천 · 보통 · 제외 평균
발표용 점수	88.47	53.15
카공 감성 점수	96.58	50.04
별점 점수	68.65	71.95
리뷰 신뢰도	0.98	0.95
카공 관련 언급 수	3.55	1.65
평균 직선거리	1,745.85m	1,245.58m

[표 18] 추천 모델 성능 비교

모델	데이터 수	특성 수	Accuracy	Precision	Recall	F1
Logistic Regression	60	12	0.9333	0.9429	0.9100	0.9159
Random Forest	60	12	0.8833	0.8529	0.8500	0.8278
XGBoost	60	12	0.8333	0.8433	0.7300	0.7566

[표 19] Logistic Regression 중요도 TOP 5

순위	특성	중요도
1	좌석_score	0.3978
2	조용함_score	0.3632
3	체류 적합성_score	0.3583
4	콘센트_score	0.1606
5	가격대_score	0.0986

[표 20] Random Forest 중요도 TOP 5

순위	특성	중요도
1	조용함_score	0.3253
2	좌석_score	0.2011
3	review_count	0.1504
4	체류 적합성_score	0.1119
5	rating_score	0.0705

[표 21] XGBoost 중요도 TOP 5

순위	특성	중요도
1	체류 적합성_score	0.3418
2	조용함_score	0.2346
3	좌석_score	0.2040
4	review_confidence	0.0828
5	rating_score	0.0630

[표 22] 모델별 중요도 TOP 5 비교

모델	1위	2위	3위	4위	5위
Logistic Regression	좌석	조용함	체류 적합성	콘센트	가격대
Random Forest	조용함	좌석	리뷰 수	체류 적합성	별점
XGBoost	체류 적합성	조용함	좌석	리뷰 신뢰도	별점

[표 23] 공통 핵심 추천 요인

핵심 요인	의미
조용함_score	소음이 적고 집중하기 좋은 환경
좌석_score	좌석 수, 테이블, 의자, 공간 여유
체류 적합성_score	오래 머물기 좋은 분위기와 이용 조건

[최종 추천 결과 그래프]

